

CAHIER DES CHARGES

Assistant Conversationnel Multimodal avec RAG

Projet Professionnel — Usage Général

Titre du projet	Assistant Conversationnel Multimodal avec RAG
Type	Projet Professionnel / Entreprise
Domaine	Usage Général — Assistant IA d'entreprise
Modalités supportées	Texte, Images, Documents (PDF), Audio
Date de rédaction	25 juin 2026
Version	1.0
Statut	En cours de validation

Confidentiel — Usage interne

1. Introduction et Contexte

1.1 Présentation du projet

Ce document constitue le cahier des charges du projet de développement d'un Assistant Conversationnel Multimodal intégrant la technologie RAG (Retrieval-Augmented Generation). Ce système vise à fournir à l'entreprise un assistant IA capable d'interagir avec les utilisateurs via plusieurs modalités (texte, image, document, audio) tout en s'appuyant sur une base de connaissances interne pour produire des réponses précises et contextualisées.

1.2 Problématique

Les entreprises font face à un volume croissant d'informations internes (documentations, rapports, bases de connaissances) difficiles à exploiter rapidement. Les solutions LLM généralistes présentent deux limites majeures :

- Manque d'ancrage dans les données propriétaires de l'entreprise
- Risque d'hallucinations sur des sujets métier spécifiques
- Incapacité à traiter simultanément plusieurs types de médias

Le RAG (Retrieval-Augmented Generation) permet de pallier ces limitations en enrichissant les requêtes avec des extraits pertinents tirés d'une base documentaire indexée.

1.3 Objectifs généraux

- Développer un assistant conversationnel multimodal (texte, image, audio, documents)
- Intégrer un pipeline RAG performant pour ancrer les réponses dans les données internes
- Offrir une interface utilisateur fluide, accessible via navigateur web
- Garantir la confidentialité et la sécurité des données de l'entreprise
- Permettre une mise à jour dynamique de la base de connaissances

2. Périmètre du Projet

2.1 Fonctionnalités incluses

2.1.1 Interface conversationnelle

- Chat textuel multiturns avec historique de conversation
- Upload et traitement d'images (JPEG, PNG, WEBP)
- Upload et traitement de documents PDF, DOCX, TXT, CSV
- Enregistrement et transcription audio (STT — Speech To Text)
- Synthèse vocale des réponses (TTS — Text To Speech, optionnel)

2.1.2 Pipeline RAG

- Ingestion et indexation automatique des documents sources
- Découpage intelligent des documents (chunking sémantique)
- Génération d'embeddings vectoriels pour chaque chunk
- Stockage dans une base de données vectorielle
- Recherche hybride (sémantique + lexicale) à chaque requête
- Injection du contexte récupéré dans le prompt du LLM
- Affichage des sources utilisées pour chaque réponse

2.1.3 Gestion de la base de connaissances

- Interface d'administration pour uploader, supprimer et mettre à jour des documents
- Support de multiples formats : PDF, DOCX, TXT, CSV, MD
- Suivi de l'état d'indexation des documents

2.1.4 Sécurité & Gestion des accès

- Authentification utilisateur (login / mot de passe, SSO possible)
- Gestion des rôles : utilisateur standard, administrateur
- Chiffrement des communications (HTTPS)
- Journalisation des interactions (logs d'audit)

2.2 Fonctionnalités exclues (hors périmètre v1)

- Appels téléphoniques ou intégration téléphonie
- Génération d'images (image-to-image, text-to-image)
- Intégration ERP / CRM (prévue pour v2)
- Application mobile native iOS/Android

3. Spécifications Fonctionnelles

3.1 Cas d'utilisation principaux

ID	Cas d'utilisation	Description	Priorité
UC-01	Chat textuel	L'utilisateur pose une question en texte et reçoit une réponse contextualisée via RAG	HAUTE
UC-02	Analyse d'image	L'utilisateur soumet une image et demande une analyse ou extraction d'informations	HAUTE
UC-03	Interrogation PDF	L'utilisateur upload un PDF et pose des questions sur son contenu	HAUTE
UC-04	Entrée audio	L'utilisateur parle et sa question est transcrite puis traitée	MOYENNE
UC-05	Historique conversation	L'utilisateur consulte et continue des conversations passées	MOYENNE
UC-06	Admin base de connaissance	L'admin upload, indexe et gère les documents sources	HAUTE
UC-07	Affichage des sources	Chaque réponse RAG cite les documents sources utilisés	HAUTE
UC-08	Synthèse vocale	L'assistant lit la réponse à voix haute (TTS)	BASSE

3.2 Flux principal d'une requête multimodale

- Étape 1 — L'utilisateur soumet sa requête (texte + éventuellement image/audio/document)
- Étape 2 — Prétraitement : transcription audio (Whisper), OCR si nécessaire, extraction texte document
- Étape 3 — Vectorisation de la requête via le modèle d'embedding
- Étape 4 — Recherche dans la base vectorielle (top-k chunks pertinents)
- Étape 5 — Construction du prompt enrichi (requête + contexte récupéré)
- Étape 6 — Appel au LLM (génération de la réponse)
- Étape 7 — Retour de la réponse avec les sources citées

4. Architecture Technique

4.1 Vue d'ensemble

L'architecture repose sur trois couches principales : le Frontend (interface utilisateur), le Backend (API et orchestration), et la couche Data (base vectorielle + stockage documentaire).

4.2 Stack technologique recommandée

Composant	Technologie(s) recommandée(s)	Rôle
Frontend	React.js / Next.js + TailwindCSS	Interface utilisateur, chat, upload fichiers
Backend / API	FastAPI (Python) ou Node.js Express	Orchestration RAG, gestion requêtes
LLM	GPT-4o / Claude 3.5 / Llama 3 (local)	Génération de réponses
Embedding	OpenAI text-embedding-3 / BGE / E5	Vectorisation documents et requêtes
Base vectorielle	Qdrant / Chroma / Weaviate / Pinecone	Stockage et recherche vectorielle
Orchestration RAG	LangChain / LlamaIndex	Pipeline RAG, chunking, retrieval
STT (Audio)	OpenAI Whisper	Transcription audio en texte
Vision (Images)	GPT-4o Vision / LLaVA	Analyse et description d'images
Stockage documents	AWS S3 / MinIO / disque local	Stockage des fichiers sources
Base de données	PostgreSQL	Utilisateurs, historique, métadonnées
Authentification	JWT / OAuth2 / Keycloak	Gestion des sessions et rôles
Conteneurisation	Docker + Docker Compose	Déploiement et portabilité

4.3 Stratégie de chunking et d'indexation

- Taille des chunks : 512 à 1024 tokens avec chevauchement de 10-20%
- Chunking sémantique (découpage par phrases/paragraphes cohérents)
- Métadonnées indexées : nom fichier, date, page, auteur, type
- Recherche hybride : similarité cosinus (dense) + BM25 (sparse) avec fusion (RRF)
- Reranking optionnel avec Cohere Rerank ou Cross-Encoder

5. Exigences Non Fonctionnelles

Catégorie	Exigence	Critère de mesure
Performance	Temps de réponse du pipeline RAG	< 5 secondes pour 90% des requêtes
Performance	Transcription audio	< 10 secondes pour un fichier de 2 min
Disponibilité	Uptime du service	> 99% en heures ouvrées
Scalabilité	Utilisateurs simultanés	Support de 50 utilisateurs concurrents minimum
Sécurité	Données sensibles	Chiffrement AES-256 au repos, TLS 1.3 en transit
Sécurité	Authentification	Session expirante, refresh token, 2FA recommandé
Maintenabilité	Couverture de tests	> 70% couverture unitaire + tests d'intégration
Accessibilité	Interface web	Compatible Chrome, Firefox, Edge — responsive desktop
Conformité	RGPD	Logs d'accès, droit à l'effacement, consentement

6. Contraintes du Projet

6.1 Contraintes techniques

- Les données de l'entreprise ne doivent pas transiter vers des API tierces sans validation de la DPO
- Privilégier des solutions open-source pour les composants critiques (base vectorielle, LLM)
- Option de déploiement on-premise obligatoire pour les données sensibles
- API RESTful documentée (OpenAPI/Swagger) pour toute intégration future

6.2 Contraintes organisationnelles

- Formation des utilisateurs finaux prévue avant la mise en production
- Validation du responsable sécurité (RSSI) avant déploiement en production
- Documentation technique et utilisateur obligatoire à la livraison

6.3 Contraintes budgétaires

- Budget API LLM à cadrer : estimé entre 200 et 800 EUR/mois selon le volume
- Prioriser les solutions avec tier gratuit pour la phase de développement/test
- Option LLM local (Ollama + Llama 3) comme alternative sans coût variable

7. Planning Prévisionnel

Phase	Intitulé	Livrables	Durée estimée
P1	Cadrage & Architecture	Cahier des charges validé, choix stack, maquettes	2 semaines
P2	Mise en place infrastructure	Environnement Docker, BDD vectorielle, pipeline RAG minimal	2 semaines
P3	Développement Core RAG	Ingestion documents, embedding, retrieval, génération réponse	3 semaines
P4	Intégration multimodale	Support image (vision), audio (Whisper), documents multi-formats	3 semaines
P5	Frontend & UX	Interface chat complète, upload, historique, admin	3 semaines
P6	Sécurité & Auth	Auth, rôles, logs, RGPD, chiffrement	2 semaines
P7	Tests & Optimisation	Tests unitaires, intégration, performance, fine-tuning RAG	2 semaines
P8	Déploiement & Formation	Mise en production, documentation, formation utilisateurs	1 semaine

Durée totale estimée : 18 semaines (environ 4,5 mois)

8. Critères d'Acceptation

8.1 Tests fonctionnels

- L'assistant répond correctement à au moins 85% des questions testées sur la base de connaissances
- Les sources citées dans les réponses sont pertinentes et traçables
- Un fichier audio de 60 secondes est transcrit et traité en moins de 15 secondes
- Une image uploadée est analysée correctement par le module vision
- Un PDF de 50 pages est indexé et interrogeable en moins de 2 minutes

8.2 Tests non fonctionnels

- Simulation de 50 utilisateurs simultanés sans dégradation > 20% du temps de réponse
- Aucune donnée utilisateur non autorisée accessible sans authentification
- Reprise de service en moins de 5 minutes en cas de redémarrage conteneur

8.3 Recette utilisateur

- Validation par un panel de 5 à 10 utilisateurs internes via questionnaire de satisfaction
- Score NPS (Net Promoter Score) cible : > 7/10
- Taux d'abandon < 10% lors des sessions de test

9. Analyse des Risques

Risque	Probabilité	Impact	Mesure d'atténuation
Hallucinations du LLM	Moyenne	Élevé	Affichage systématique des sources + seuil de confiance RAG
Coûts API LLM dépassés	Moyenne	Moyen	Monitoring de tokens, rate limiting, fallback LLM local
Qualité du chunking insuffisante	Élevée	Élevé	Tests itératifs, chunking sémantique, évaluation avec RAGAS
Fuite de données sensibles	Faible	Très élevé	Déploiement on-premise, audit sécurité, chiffrement bout en bout
Latence trop élevée	Moyenne	Moyen	Streaming de réponses, cache vectoriel, optimisation top-k
Résistance des utilisateurs	Faible	Moyen	Formation, UX soignée, onboarding progressif
Dépendance fournisseur LLM	Moyenne	Élevé	Architecture modulaire permettant de changer de LLM

10. Glossaire

Terme	Définition
RAG	Retrieval-Augmented Generation : technique combinant recherche documentaire et génération LLM
LLM	Large Language Model : modèle de langage de grande taille (GPT-4, Claude, Llama...)
Embedding	Représentation vectorielle dense d'un texte dans un espace mathématique
Chunking	Découpage d'un document en segments (chunks) pour l'indexation
STT	Speech-To-Text : conversion d'audio en texte (transcription)
TTS	Text-To-Speech : synthèse vocale, conversion texte en audio
Top-k	Nombre de chunks les plus pertinents récupérés lors d'une recherche vectorielle
RRF	Reciprocal Rank Fusion : algorithme de fusion pour la recherche hybride
RAGAS	Framework d'évaluation automatique de la qualité d'un pipeline RAG
On-premise	Déploiement sur les serveurs internes de l'entreprise (vs cloud public)
Multimodal	Système capable de traiter plusieurs types de médias (texte, image, audio...)